

Статистические свойства оценок

Эконометрика. Лекция 2

- стандартные предпосылки для модели линейной регрессии
- доверительные интервалы для коэффициентов
- гипотезы о коэффициентах

Условное математическое ожидание

r — одна случайная величина

s — одна случайная величина

$E(s|r)$ — это такая функция от случайной величины r , которая наиболее похожа на случайную величину s

$E(s|r)$ — это случайная величина \tilde{s} :

- ① представимая в виде $\tilde{s} = f(r)$
- ② $E(\tilde{s}) = E(s)$
- ③ $Cov(s - \tilde{s}, g(r)) = 0$ для любой $g(r)$.

Или: $Cov(s, g(r)) = Cov(\tilde{s}, g(r))$

Теорема:

Если величина r дискретна и принимает значения a , b или c , то

$$E(s|r) = \begin{cases} E(s|r = a), & \text{если } r = a \\ E(s|r = b), & \text{если } r = b \\ E(s|r = c), & \text{если } r = c \end{cases}$$

Задача [у доски]

s, r	$r = 1$	$r = 2$
$s = 0$	0.25	0.2
$s = 10$	0.25	0.3

Найдите: $E(s|r)$, $E(s^2|r)$

Если величины непрерывны и есть совместная функция плотности

Теорема:

Если пара величин x, y имеет функцию плотности $f(r, s)$, то

$$E(s|r) = \int_{-\infty}^{\infty} s \cdot f(s|r) dx$$

где $f(s|r) = f(r, s)/f(r)$ — условная функция плотности

Пусть a, b — константы, s, r — случайные величины.

Идея: свойства $E(s|r)$ аналогичны свойствам $E(s)$, если считать r и любую функцию $h(r)$ константой.

- $E(E(s|r)) = E(s)$
- $E(as + b|r) = aE(s|r) + b$
- $E(h(r)|r) = h(r)$
- $E(h(r)s|r) = h(r)E(s|r)$

Условная дисперсия и ковариация

Обычная дисперсия: $Var(s) = E(s^2) - (E(s))^2$

Условная дисперсия. $Var(s|r) = E(s^2|r) - (E(s|r))^2$

Обычная ковариация: $Cov(s_1, s_2) = E(s_1 s_2) - E(s_1)E(s_2)$

Условная ковариация: $Cov(s_1, s_2|r) = E(s_1 s_2|r) - E(s_1|r)E(s_2|r)$

Задача [у доски]

s, r	$r = 1$	$r = 2$
$s = 0$	0.25	0.2
$s = 10$	0.25	0.3

Найдите: $Var(s|r)$

Свойства условной дисперсии

Пусть a, b — константы, s, r — случайные величины.

Идея: свойства $\text{Var}(s|r)$ аналогичны свойствам $\text{Var}(s)$, если считать r и любую функцию $h(r)$ константой.

Свойства условной дисперсии


$$\text{Var}(as + b|r) = a^2 \text{Var}(s|r)$$

$$\text{Var}(s + h(r)|r) = \text{Var}(s|r)$$

$$\text{Var}(h(r)s|r) = h^2(r) \text{Var}(s|r)$$

$$\text{Var}(s) = \text{Var}(E(s|r)) + E(\text{Var}(s|r))$$

Геометрическая интерпретация [у доски]



Мораль геометрической интерпретации:

Если считать, что $Cov(r, s)$ — скалярное произведение, то

- квадрат длины случайной величины r — дисперсия, $Var(r)$
- косинус угла между случайными величинами — корреляция, $Corr(s, r)$

Верны “школьные” теоремы: теорема Пифагора, Фалеса, etc

Предпосылки на ошибки

- $E(\varepsilon_i|X) = 0$
- $E(\varepsilon_i^2|X) = \sigma^2$ или $Var(\varepsilon_i|X) = \sigma^2$
- $E(\varepsilon_i\varepsilon_j|X) = 0$ или $Cov(\varepsilon_i, \varepsilon_j|X) = 0$

Ковариационная матрица вектора ε :

$$Var(\varepsilon) = \begin{pmatrix} Var(\varepsilon_1) & Cov(\varepsilon_1, \varepsilon_2) & Cov(\varepsilon_1, \varepsilon_3) & \dots \\ Cov(\varepsilon_2, \varepsilon_1) & Var(\varepsilon_2) & Cov(\varepsilon_2, \varepsilon_3) & \dots \\ Cov(\varepsilon_3, \varepsilon_1) & Cov(\varepsilon_3, \varepsilon_2) & Var(\varepsilon_3) & \dots \\ \vdots & & & \end{pmatrix}$$

Запись предпосылок с помощью ковариационной матрицы

$$\text{Var}(\varepsilon|X) = \begin{pmatrix} \sigma^2 & 0 & 0 & \dots \\ 0 & \sigma^2 & 0 & \dots \\ 0 & 0 & \sigma^2 & \dots \\ \vdots & \vdots & \vdots & \end{pmatrix} = \sigma^2 \begin{pmatrix} 1 & 0 & 0 & \dots \\ 0 & 1 & 0 & \dots \\ 0 & 0 & 1 & \dots \\ \vdots & \vdots & \vdots & \end{pmatrix} = \sigma^2 \cdot I_{n \times n}$$

Дисперсия и ковариация оценок коэффициентов

Предпосылки:

- $Var(\varepsilon|X) = \sigma^2 \cdot I_{n \times n}$
- $Var(\varepsilon_i|X) = \sigma^2$
- $Cov(\varepsilon_i, \varepsilon_j|X) = 0$
- $y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$

Позволяют посчитать $Var(\hat{\beta}_j|X)$, $Cov(\hat{\beta}_j, \hat{\beta}_l|X)$

Пример вычислений в парной регрессии [у доски]

В модели $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$

Предположим, что: $\text{Var}(\varepsilon_i|X) = \sigma^2$, $\text{Cov}(\varepsilon_i, \varepsilon_j|X) = 0$

Найдите $\text{Var}(\hat{\beta}_2|X)$, $\text{Cov}(\hat{\beta}_1, \hat{\beta}_2|X)$, $\text{Var}(\hat{\beta}_1|X)$

Итого в парной регрессии:

- $Var(\hat{\beta}_2|X) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$
- $Cov(\hat{\beta}_1, \hat{\beta}_2|X) = \frac{-\bar{x}\sigma^2}{\sum (x_i - \bar{x})^2}$
- $Var(\hat{\beta}_1|X) = \frac{\sigma^2 \sum x_i^2}{n \sum (x_i - \bar{x})^2}$

- Зачем придумали эту условную дисперсию, если все свойства аналогичны обычной дисперсии?
- А вот как раз и придумали, чтобы всё аналогично просто считалось! Настоящая безусловная дисперсия оценок коэффициентов — гораздо сложнее, чем условная.

Теорема (без доказательства):

$$\text{Var}(\hat{\beta}_j|X) = \sigma^2 / \text{RSS}_j$$

RSS_j — сумма квадратов остатков в регрессии j -ой объясняющей переменной на остальные объясняющие переменные (включая константу)

ЛИНАЛ. Ковариационная матрица оценок коэффициентов

Средствами линейной алгебры можно доказать, что:

$$\text{Var}(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$$

ЛИНАЛ. Предварительная информация к доказательству:

Свойство: $Var(Ay) = A \cdot Var(y) \cdot A'$

Это матричный аналог свойства $Var(a \cdot y_1) = a^2 \cdot Var(y_1)$.

Напомним, что $(AB)' = B'A'$ и $(A^{-1})' = (A')^{-1}$

Поэтому:

- $(X'X)' = X'X'' = X'X$
- $((X'X)^{-1})' = (X'X)^{-1}$

ЛИНАЛ. доказательство формулы [у доски]

Если оценки МНК существуют и единственны, $\text{Var}(\varepsilon|X) = \sigma^2 I_{n \times n}$

то ковариационная матрица равна:

$$\text{Var}(\hat{\beta}|X) = \sigma^2 (X'X)^{-1}$$

Как оценить σ^2 ?

Константа σ^2 неизвестна.

Случайная величина $\hat{\sigma}^2 = \frac{RSS}{n-k}$ — замечательная оценка для σ^2 .

Замечательная в смыслах:

- $E(\hat{\sigma}^2) = \sigma^2$, в среднем оценивает верно
- $\hat{\sigma}^2 \rightarrow \sigma^2$ по вероятности с ростом n

Оценка ковариационной матрицы

Идея: заменим во всех формулах σ^2 на $\hat{\sigma}^2$:

- Истинная дисперсия: $\text{Var}(\hat{\beta}_j|X) = \sigma^2 \cdot f(X)$
- Оценка дисперсии: $\widehat{\text{Var}}(\hat{\beta}_j|X) = \hat{\sigma}^2 \cdot f(X)$

а именно: $\widehat{\text{Var}}(\hat{\beta}_j|X) = \hat{\sigma}^2 / \text{RSS}_j$

- $\text{se}(\hat{\beta}_j) = \sqrt{\widehat{\text{Var}}(\hat{\beta}_j|X)}$

Например, в модели $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i$: $\text{se}(\hat{\beta}_2) = \sqrt{\frac{\hat{\sigma}^2}{\sum (x_i - \bar{x})^2}}$

$$\widehat{Var}(\hat{\beta}|X) = \begin{pmatrix} \widehat{Var}(\hat{\beta}_1|X) & \widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2|X) & \widehat{Cov}(\hat{\beta}_1, \hat{\beta}_3|X) & \dots \\ \widehat{Cov}(\hat{\beta}_2, \hat{\beta}_1|X) & \widehat{Var}(\hat{\beta}_2|X) & \widehat{Cov}(\hat{\beta}_2, \hat{\beta}_3|X) & \dots \\ \widehat{Cov}(\hat{\beta}_3, \hat{\beta}_1|X) & \widehat{Cov}(\hat{\beta}_3, \hat{\beta}_2|X) & \widehat{Var}(\hat{\beta}_3|X) & \dots \\ \vdots & & & \ddots \end{pmatrix}$$

- ЛИНАЛ: $\widehat{Var}(\hat{\beta}|X) = \hat{\sigma}^2 \cdot (X'X)^{-1}$
- В R: `vcov(model)`

- Базовые:

верны даже на малых выборках без предположения о нормальности ε_i

- Асимптотические:

верны на больших выборках даже без предположения о нормальности ε_i

- При нормальности:

верны при нормальности ε_i даже на малых выборках

Если:

- ❶ Истинная зависимость имеет вид $y_i = \beta_1 + \beta_2 x_i + \beta_3 z_i + \varepsilon_i$
 - В матричном виде: $y = X\beta + \varepsilon$
- ❷ С помощью МНК оценивается регрессия y на константу, x_i , z_i
 - В матричном виде: $\hat{\beta} = (X'X)^{-1}X'y$
- ❸ Наблюдений больше, чем оцениваемых коэффициентов β : $n > k$

Если:

- ④ Строгая экзогенность: $E(\varepsilon_i | \text{все регрессоры}) = 0$
 - В матричном виде: $E(\varepsilon_i | X) = 0$
- ⑤ Условная гомоскедастичность: $E(\varepsilon_i^2 | \text{все регрессоры}) = \sigma^2$
 - В матричном виде: $E(\varepsilon_i^2 | X) = \sigma^2$
- ⑥ $\text{Cov}(\varepsilon_i, \varepsilon_j | X) = 0$ при $i \neq j$

Если:

- 7 векторы отдельных наблюдений (x_i, z_i, y_i) — независимы и одинаково распределены
- 8 с вероятностью 1 среди регрессоров нет линейно зависимых
- Синонимы в матричном виде: $\text{rank}(X) = k$ или $\det(X'X) \neq 0$ или $(X'X)^{-1}$ существует

То:

- Оценки $\hat{\beta}_j$ линейны по y_i : $\hat{\beta}_j = c_1 y_1 + \dots + c_n y_n$
- Оценки несмещены: $E(\hat{\beta}_j|X) = \beta_j$, и в частности $E(\hat{\beta}_j) = \beta_j$

То:

- Оценки эффективны среди линейных и несмещенных

Для любой линейной по y_i и несмещенной альтернативной оценки $\hat{\beta}^{alt}$:

$$Var(\hat{\beta}_j^{alt}|X) \geq Var(\hat{\beta}_j|X) \text{ и } Var(\hat{\beta}_j^{alt}) \geq Var(\hat{\beta}_j)$$

То:

- Ковариационная матрица: $\text{Var}(\hat{\beta}|X) = \sigma^2(X'X)^{-1}$

Дисперсии: $\text{Var}(\hat{\beta}_j|X) = \sigma^2/RSS_j$

- $\text{Cov}(\hat{\beta}_j, \hat{\varepsilon}_i|X) = 0$
- $E(\hat{\sigma}^2|X) = \sigma^2$, и $E(\hat{\sigma}^2) = \sigma^2$

То при $n \rightarrow \infty$:

- $\hat{\beta}_j \rightarrow \beta_j$ по вероятности
- $\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \rightarrow N(0, 1)$ по распределению
- $\hat{\sigma}^2 \rightarrow \sigma^2$ по вероятности

$$\hat{\sigma}^2 = \frac{RSS}{n-k}$$

Если дополнительно известно, что $\varepsilon_i \sim N(0, \sigma^2)$, то:

- Оценки эффективны среди несмещенных
- $\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} | X \sim t_{n-k}, \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}$
- $RSS/\sigma^2 | X \sim \chi_{n-k}^2, RSS/\sigma^2 \sim \chi_{n-k}^2$

Доверительные интервалы для коэффициентов

Возможно строить в двух подходах:

- Асимптотически: $t = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \rightarrow N(0, 1)$
- При нормальности: $t = \frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim t_{n-k}$

Примерный 95%-ый интервал:

$$[\hat{\beta}_j - 2se(\hat{\beta}_j); \hat{\beta}_j + 2se(\hat{\beta}_j)]$$

Описание любого теста:

- предпосылки теста

например: асимптотический или требующий нормальности ошибок ε_i

- проверяемая H_0 против H_a
- формула для вычисления статистики
- закон распределения статистики при верной H_0

Практическая последовательность действий

- 1 выбираем уровень значимости α ,
 $\alpha = P(H_0 \text{ отвергнута} \mid H_0 \text{ верна})$
- 2 находим наблюдаемое значение статистики S_{obs}
- 3 находим критическое значение статистики S_{cr}
- 4 сравниваем критическое и наблюдаемое S_{obs} и S_{cr}

(можно сравнить Р-значение и уровень значимости α)

- 5 вывод: “ H_0 отвергается” или “ H_0 не отвергается”

Проверка гипотез и построение доверительных интервалов [у доски]

```
summary(model)
      Estimate Std. Error t value Pr(>|t|)
(Intercept) 59.86392    3.98754  15.013  <2e-16 ***
Agriculture  0.10953    0.07848   1.396   0.1698
Catholic     0.11496    0.04274   2.690   0.0101 *
```

Residual standard error: 11.07

- проверьте гипотезу $\beta_a = 0$
- постройте доверительный интервал для β_a
- постройте доверительный интервал для σ^2

стандартные ошибки часто выписывают под коэффициентами

$$\widehat{Fertility}_i = 59.8 + 0.109 Agriculture_i + 0.115 Catholic_i$$

(3.98) (0.078) (0.042)

Стандартная табличка в любом статистическом пакете [у доски]

Estimate Std. Error t value Pr(>|t|)

(Intercept)	59.86392	3.98754	15.013	<2e-16 ***
Agriculture	0.10953	0.07848	1.396	0.1698
Catholic	0.11496	0.04274	2.690	0.0101 *

Особые моменты при проверки гипотез

- Плохое устоявшееся название гипотез
- Смысл формулировки “ H_0 не отвергается”
- Значимость и существенность — разные вещи
- Проблема множественных сравнений

Проверка значимости — на самом деле проверка незначимости:

- “Мы проверили значимость коэффициента при доходе”
- Мы проверили $H_0 : \beta_{inc} = 0$.

Смысл “ H_0 не отвергается”

- недостаточно данных чтобы отвергнуть H_0
- имеющиеся данные не противоречат H_0

Вполне возможно, что данные не противоречат H_a (!)

Значимость и существенность

- Коэффициент может быть значимым и совершенно несущественным

На огромных выборках как правило все коэффициенты значимы

- Коэффициент может быть существенным, но незначимым

Значимость — статистическое отвержение гипотезы о точном равенстве

Существенность — насколько данное отличие от нуля важно в прикладном смысле

Стандартизированные коэффициенты

Существенность — можно придать разный математический смысл

Например:

- стандартизировать переменные:

$$y_i^{st} := \frac{y_i - \bar{y}}{sd(y)}, \quad x_i^{st} := \frac{x_i - \bar{x}}{sd(x)}, \quad z_i^{st} := \frac{z_i - \bar{z}}{sd(z)}$$

- переоценить модель:

$$y_i^{st} = \beta_1^{st} + \beta_2^{st} x_i^{st} + \beta_3^{st} z_i^{st} + \varepsilon_i^{st}$$

Проблема множественных сравнений

- Исследователь хочет проверить гипотезу о том, что $\beta_{42} = 0$. Ok.
- Исследователь хочет выяснить какие регрессоры из 100 значимы. Плохой метод.

Проверка гипотезы об одном ограничении

Хотим проверить гипотезу о $\beta_2 - \beta_3$.

Статистика $t = \frac{\hat{\beta}_2 - \hat{\beta}_3 - (\beta_2 - \beta_3)}{se(\hat{\beta}_2 - \hat{\beta}_3)}$ распределена

- асимптотически $N(0, 1)$
- при нормальности t_{n-k}

Хотим проверить гипотезу $\beta_2 = \beta_3$ или $\beta_2 - \beta_3 = 0$

Всегда можно переформулировать модель так, что $\beta_2 - \beta_3$ станет новым коэффициентом $\beta'_2 = \beta_2 - \beta_3$.

Пример проверки гипотезы о связи коэффициентов [у доски]

```
summary(model)
      Estimate Std. Error t value Pr(>|t|)
(Intercept) 59.86392    3.98754  15.013  <2e-16 ***
Agriculture  0.10953    0.07848   1.396   0.1698
Catholic     0.11496    0.04274   2.690   0.0101 *
vcov(model)
      (Intercept) Agriculture    Catholic
(Intercept) 15.900471817 -0.256680712 -0.006998292
Agriculture -0.256680712  0.006159437 -0.001345371
Catholic    -0.006998292 -0.001345371  0.001826622
Residual standard error: 11.07
```

Проверьте гипотезу $\beta_a = \beta_c$ (два способа)

Мораль лекции 2:

В этой лекции мы научились:

- строить доверительные интервалы
- проверять гипотезы об отдельном коэффициенте
- сформулировали стандартные предпосылки

В следующей:

- более сложные гипотезы
- прогнозирование