

handout_1 2 3

Содержание

Лекция 1. Метод наименьших квадратов без статистики	1
Лекция 2.	1
Лекция 3.	1
Геометрическая иллюстрация МНК	1
Вывод формулы для оценок коэффициентов	2
Матрица-шляпница	2
Математическое ожидание и ковариационная матрица	3
Статистические свойства МНК оценок	4
Лекция 4. Мультиколлинеарность. Метод главных компонент.	5
Лекция 5. Гетероскедастичность.	5
Лекция 6. Автокорреляция.	5
Лекция 7. Метод максимального правдоподобия. Логит и пробит-модели.	5
Лекция 8. Процессы авторегрессии и скользящего среднего	5
Лекция 9. Инструментальные переменные	5
Лекция 10. Квантильная регрессия. Случайный лес. Байесовский подход.	5

Лекция 1. Метод наименьших квадратов без статистики

Лекция 2.

Лекция 3.

Геометрическая иллюстрация МНК

Тут картинка.

Вывод формулы для оценок коэффициентов

Если вектор y перпендикулярен вектору x , то их скалярное произведение должно быть равно нулю, т.к. $\cos(90^\circ) = 0$, а скалярное произведение равно:

$$(x, y) = |x| \cdot |y| \cdot \cos(x, y)$$

С другой стороны, скалярное произведение равно

$$(x, y) = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = \sum_{i=1}^n x_i y_i = x' y$$

Значит условие перпендикулярности векторов x и y можно кратко записать как $x' y = 0$. Столбца матрицы регрессоров X ортогональны остаткам регрессии, вектору $\hat{\varepsilon}$:

$$X' \hat{\varepsilon} = 0$$

Заметим, что здесь 0 — это вектор размера $k \times 1$. Подставляем формулу для остатков, $\hat{\varepsilon} = y - X' \hat{\beta}$:

$$X'(y - X \hat{\beta}) = 0$$

Раскрываем скобки и переносим в разные стороны уравнения:

$$X' y - X' X \hat{\beta} = 0$$

$$X' X \hat{\beta} = X' y$$

Матрица X' имеет размер $k \times n$, поэтому на неё сокращать нельзя. Хотя иногда хочется :) А вот обратная матрица к матрице $X' X$ существует, если среди столбцов X нет линейно зависимых и $n \geq k$. Домножаем обе части уравнения слева на $(X' X)^{-1}$:

$$\hat{\beta} = (X' X)^{-1} X' y$$

Ура! Мы получили формулу для МНК-оценок множественной регрессии! Заметьте, что она подозрительно похожа на формулу МНК-оценки для случая одного оцениваемого параметра. В модели $y_i = \beta x_i + \varepsilon_i$ МНК-оценка коэффициента β имела вид $\hat{\beta} = \sum x_i y_i / \sum x_i^2$.

Матрица-шляпница

Если $\hat{\beta} = (X' X)^{-1} X' y$, то вектор прогнозов, \hat{y} , будет равен $\hat{y} = X \hat{\beta} = X (X' X)^{-1} X' y$. Матрицу $H = X (X' X)^{-1} X'$ по-английски называют “hat-matrix”, матрицей-шляпницей, потому, что она надевает на y шляпку: $\hat{y} = H \cdot y$. Умножение любого вектора на матрицу H проецирует этот вектор на пространство, порожаемое регрессорами. Поскольку сами регрессоры уже лежат в этом пространстве, то $H \cdot X = X$. Матрица H идемпотентная, то есть возведенная в произвольную натуральную степень даст саму себя, $H^n = H$. В этом легко можно убедиться либо перемножив руками H на H ,

$$H \cdot H = X (X' X)^{-1} X' X (X' X)^{-1} X' = X (X' X)^{-1} X' = H$$

либо из геометрических соображений. Умножение на H несколько раз подряд, это проецирование результата проецирования. А проекция от проекции совпадает с проекцией.

Собственными числами матрицы H могут быть только нули или единицы. Действительно, при проецировании часть векторов сохраняются (те, что лежали в пространстве регрессоров), часть превращается в ноль (те, что были ортогональны пространству регрессоров), а все другие при проецировании меняют направление.

Ранг матрицы-шляпицы можно посчитать, воспользовавшись тем, что $rk(AB) = rk(BA)$:

$$rk(X(X'X)^{-1}X') = rk(X'X(X'X)^{-1}) = rk(I_{k \times k}) = k$$

Математическое ожидание и ковариационная матрица

Если $y = (y_1, \dots, y_n)'$ — случайный вектор, то для него определены математическое ожидание, $E(y)$, и ковариационная матрица, $Var(y)$.

Определение. Если y — вектор-столбец случайных величин,

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \text{ то } E(y) = \begin{pmatrix} E(y_1) \\ E(y_2) \\ \vdots \\ E(y_n) \end{pmatrix}$$

Определение. $Var(y) = E(yy') - E(y)E(y')$.

Согласно определению ковариационной матрицы:

$$Var(y) = \begin{pmatrix} Var(y_1) & Cov(y_1, y_2) & \cdots & Cov(y_1, y_n) \\ Cov(y_2, y_1) & Var(y_2) & \cdots & Cov(y_2, y_n) \\ Cov(y_3, y_1) & Cov(y_3, y_2) & \cdots & Cov(y_3, y_n) \\ \vdots & \vdots & \vdots & \vdots \\ Cov(y_n, y_1) & Cov(y_n, y_2) & \cdots & Var(y_n) \end{pmatrix}$$

Определение. $Cov(y, z) = E(yz') - E(y)E(z')$

Свойства:

Если A и B — неслучайные матрицы, a и b — неслучайные вектора, y и w — случайные вектора подходящих размеров, все математические ожидания и ковариационные матрицы существуют, то:

$$E(a) = a$$

$$E(Ay + b) = AE(y) + b \text{ и } E(yA + b) = E(y)A + b$$

$$E(y + w) = E(y) + E(w)$$

$$Var(a) = 0$$

$$Var(Ay + b) = AVar(y)A'$$

$$Var(y + z) = Var(y) + Var(z) + Cov(y, z) + Cov(z, y)$$

$$Cov(Ay + a, Bz + b) = ACov(y, z)B'$$

$$Cov(y, z) = Cov(z, y)'$$

$$Cov(y + z, w) = Cov(y, w) + Cov(z, w) \text{ и } Cov(y, z + w) = Cov(y, z) + Cov(y, w)$$

$$Cov(y, y) = Var(y)$$

Статистические свойства МНК оценок

Если:

1. Истинная зависимость имеет вид $y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i$
В матричном виде: $y = X\beta + \varepsilon$
2. С помощью МНК оценивается регрессия y на константу, x_2, x_3, \dots, x_k
В матричном виде: $\hat{\beta} = (X'X)^{-1}X'y$
3. Наблюдений больше, чем оцениваемых коэффициентов β : $n > k$
4. Строгая экзогенность: $E(\varepsilon_i | \text{все } x_{ij}) = 0$
В матричном виде: $E(\varepsilon_i | X) = 0$
5. Условная гомоскедастичность: $E(\varepsilon_i^2 | \text{все } x_{ij}) = \sigma^2$
В матричном виде: $E(\varepsilon_i^2 | X) = \sigma^2$
6. $Cov(\varepsilon_i, \varepsilon_j | X) = 0$ при $i \neq j$
7. вектора $(x_{i.}, y_i)$ — независимы и одинаково распределены
8. с вероятностью 1 среди регрессоров нет линейно зависимых $rank(X) = k \det(X'X) \neq 0 (X'X)^{-1}$ существует

То (свойства для конечных выборок, не требующие нормальности ε):

тГМ МНК оценки $\hat{\beta}$ линейны по y : $\hat{\beta}_j = c_1 y_1 + \dots + c_n y_n$

тГМ $E(\hat{\beta} | X) = \beta$, и в частности $E(\hat{\beta}) = \beta$

тГМ Для любой альтернативной оценки $\hat{\beta}^{alt}$ удовлетворяющей свойствам 1 и 2: $Var(\hat{\beta}_j^{alt} | X) \geq Var(\hat{\beta}_j | X)$
 $Var(\hat{\beta}_j^{alt}) \geq Var(\hat{\beta}_j)$

1. $Var(\hat{\beta} | X) = \sigma^2 (X'X)^{-1}$
2. $Cov(\hat{\beta}, \hat{\varepsilon} | X) = 0$
3. $E(\hat{\sigma}^2 | X) = \sigma^2$, и $E(\hat{\sigma}^2) = \sigma^2$?остается ли при условной ГК?

свойства для конечных выборок, требующие нормальности ε Если дополнительно известно, что $\varepsilon | X \sim N$, (в частности ε и X независимы) то:

1. $t | X \sim t_{n-k}$, $t \sim t_{n-k}$
2. $RSS/\sigma^2 | X \sim \chi_{n-k}^2$, $RSS/\sigma^2 \sim \chi_{n-k}^2$
3. F тест $F | X \sim F$

Асимптотические свойства:

1. $\hat{\beta} \rightarrow \beta$ по вероятности
2. $t \rightarrow N(0, 1)$
3. $rF \rightarrow \chi_r^2$, r — число ограничений
4. $nR^2 \rightarrow \chi_{k-1}^2$ $\frac{RSS}{n-k} \rightarrow \sigma^2$

Лекция 4. Мультиколлинеарность. Метод главных компонент.

Лекция 5. Гетероскедастичность.

Лекция 6. Автокорреляция.

Лекция 7. Метод максимального правдоподобия. Логит и пробит-модели.

Лекция 8. Процессы авторегрессии и скользящего среднего

Лекция 9. Инструментальные переменные

Лекция 10. Квантильная регрессия. Случайный лес. Байесовский подход.